



ZAMAN SERİLERİ ANALİZİ

ÖDEV 3

-R PROGRAMLAMA

GAMZE ZORLU 180410806
NAZLICAN KALENDER 180410045

1-)

```
install.packages("openxlsx")
```

```
library(openxlsx)
```

```
veri <- read.xlsx("odev3.xlsx")
```

```
install.packages("forecast")
```

```
library(forecast)
```

```
install.packages("fpp")
```

```
library(fpp)
```

```
install.packages("tseries")
```

```
library(tseries)
```

Öncelikle exceldeki verimizi R'a yükleyip, 1953-1973 arasındaki veriyi zaman serisine çeviriyoruz.

```
veri_ts <- ts(veri, start = c(1953), end = c(1973, 4), frequency = 4)
```

	Year	Quarter	Capital
52	1965	4	4838
53	1966	1	5222
54	1966	2	5406
55	1966	3	5705
56	1966	4	5871
57	1967	1	5953
58	1967	2	5868
59	1967	3	5573
60	1967	4	5672
61	1968	1	5543
62	1968	2	5526
63	1968	3	5750
64	1968	4	5761
65	1969	1	5943
66	1969	2	6212
67	1969	3	6631
68	1969	4	6828
69	1970	1	6645
70	1970	2	6703
71	1970	3	6659
72	1970	4	6337
73	1971	1	6165
74	1971	2	5875
75	1971	3	5798
76	1971	4	5921
77	1972	1	5772
78	1972	2	5874
79	1972	3	5872
80	1972	4	6159
81	1973	1	6583
82	1973	2	6961
83	1973	3	7449
84	1973	4	8093

```
fit1 <- holt(veri_capital_ts, 4) #holt üster düzgünlestirmesi
```

```
accuracy(fit1) #holt için mape değerleri
```

```
fit2 <- hw(veri_capital_ts, 4) #holt winter üstel düzgünlestirmesi
```

```
accuracy(fit2) #holt winter için mape degeri
```

```
>
>
> fit1 <- holt(veri_capital_ts, 4) #holt üster düzgünlestirmesi
> accuracy(fit1) #holt için mape değerleri
      ME      RMSE      MAE      MPE      MAPE      MASE
Training set 8.177836 141.5599 112.9109 0.331441 3.049583 0.2105664
ACF1
Training set 0.01678312
> fit2 <- hw(veri_capital_ts, 4) #holt winter üstel düzgünlestirmesi
> accuracy(fit2) #holt winter için mape degeri
      ME      RMSE      MAE      MPE      MAPE      MASE
Training set 8.372824 139.8794 110.9064 0.3503737 3.007301 0.2068282
ACF1
Training set 0.02129737
> |
```

Holt ve Holt Winters yöntemleri ile yaptığımız düzgünleştirmelerin MAPE değerlerini karşılaştırdığımızda Holt Winters'ın MAPE değeri=3.007 < Holt MAPE değeri=3.049 olduğundan Holt Winters üstel düzgünleştirmesini tercih ederiz.


```
fit2 # holt winters
```

```
>
>
> fit2 # holt winters
      Point Forecast      Lo 80      Hi 80      Lo 95      Hi 95
1974 Q1      8656.706 8468.244 8845.167 8368.479 8944.932
1974 Q2      9255.108 8881.140 9629.077 8683.173 9827.044
1974 Q3      9879.493 9267.443 10491.542 8943.443 10815.542
1974 Q4     10505.303 9615.392 11395.215 9144.301 11866.306
>
>
>
```



Orijinal verideki 1974 yılı değerleri ile yaptığımız öngörüdeki 1974 yılındaki değerleri karşılaştırdığımızda öngörümüzün tutarlı olduğunu görmekteyiz.

2-)

`autoplot(veri_ts)`




`tsdisplay(veri_ts)`



ACF grafiğini kontrol ettiğimizde yavaş yavaş sönüğünü görüyoruz bundan dolayı durağan olmadığını söyleyebiliriz.

```
seasonplot(veri_ts, s=4, col = rainbow(21), year.labels =TRUE, main = "seasonal plot" )
```




Mevsimsellik grafiğini çizdirdiğimizde seride mevsimsellik olduğunu görüyoruz.

```
decomposed_veri <- decompose(x=veri_ts, type = "multiplicative")
```

```
str(decomposed_veri)
```

```
plot(decomposed_veri)
```



Zaman serisindeki mevsimsellik ve trend faktörlerinin ayrı ayrı grafiklerini çizdirip incelediğimizde trendin ve mevsimselliğin olduğunu görüyoruz.

```
lambda=BoxCox.lambda(veri_capital_ts); lambda
```

```
>
>
> lambda=BoxCox.lambda(veri_capital_ts); lambda
[1] 0.301168
>
>
>
```

Box-Cox testi uyguladığımızda lambda değerinin 0.30 olduğunu görmekteyiz. Lambda 1 olmadığı için varyansta durağan olmadığını görüyoruz, dönüşüm yapmamız gerekiyor.

```
veri_ts_boxcox <- BoxCox(veri_capital_ts, lambda)
```

```
veri_ts_boxcox
```

```
>
> veri_ts_boxcox <- BoxCox(veri_capital_ts, lambda)
> veri_ts_boxcox
      Qtr1      Qtr2      Qtr3      Qtr4
1953 29.79131 29.81535 29.82016 29.65105
1954 29.74310 29.76723 29.26177 29.34645
1955 29.00970 29.39603 30.06305 30.88911
1956 32.19153 33.30430 33.90963 34.80472
1957 35.27338 35.34070 35.23624 34.36156
1958 32.52742 31.01794 30.11490 29.49957
1959 29.78650 30.35753 30.57796 31.38061
1960 32.29347 32.67086 32.62319 32.29754
1961 31.77259 31.49671 31.41510 31.78520
1962 31.86065 31.69247 32.11770 32.01871
1963 32.13825 32.33001 33.08955 33.45970
1964 34.19311 34.76998 35.50118 36.47407
1965 37.16681 37.85922 38.68428 39.42552
1966 40.42019 40.87876 41.60120 41.99091
1967 42.18059 41.98394 41.28560 41.52278
1968 41.21315 41.17197 41.70762 41.73354
1969 42.15756 42.76794 43.68292 44.09918
1970 43.71278 43.83604 43.74260 43.04531
1971 42.66265 42.00021 41.82049 42.10679
1972 41.75943 41.99789 41.99324 42.64916
1973 43.58019 44.37549 45.35877 46.58973
>
>
>
>
```

Dönüşümünü yaptığımız serinin durağan olup olmadığını anlamak için ADF testi yapıyoruz.

```
adf_test <- adf.test(veri_ts_boxcox); adf_test
```

```
>
> adf_test <- adf.test(veri_ts_boxcox); adf_test
      Augmented Dickey-Fuller Test

data: veri_ts_boxcox
Dickey-Fuller = -2.0444, Lag order = 4, p-value = 0.5577
alternative hypothesis: stationary
>
>
>
```

$p < \alpha$ olduğundan dolayı serinin birim kökünün olduğunu, durağan olmadığını görmekteyiz.

Veriyi trendden ayırıp, durağanlaştırmak için 1. dereceden fark alıyoruz.

```
diff_1 <- diff(veri_ts_boxcox);diff_1
```

```
adf_1_test <- adf.test(diff_1); adf_1_test
```

```
>
> diff_1 <- diff(veri_ts_boxcox);diff_1
      Qtr1      Qtr2      Qtr3      Qtr4
1953      0.024043903  0.004803925 -0.169108025
1954  0.092050480  0.024125232 -0.505457900  0.084681253
1955 -0.336750463  0.386325974  0.667020480  0.826061242
1956  1.302420741  1.112775261  0.605328233  0.895087389
1957  0.468662992  0.067322812 -0.104466813 -0.874678739
1958 -1.834141842 -1.509475227 -0.903042959 -0.615328647
1959  0.286927051  0.571035198  0.220424671  0.802651704
1960  0.912865269  0.377385533 -0.047666694 -0.325655049
1961 -0.524951281 -0.275877040 -0.081606588  0.370095425
1962  0.075450923 -0.168182752  0.425237119 -0.098990609
1963  0.119533077  0.191763382  0.759545347  0.370141226
1964  0.733418040  0.576868253  0.731196366  0.972890789
1965  0.692739152  0.692412283  0.825054930  0.741240033
1966  0.994677837  0.458563927  0.722438968  0.389718055
1967  0.189674685 -0.196649012 -0.698335549  0.237176276
1968 -0.309628724 -0.041178096  0.535643448  0.025925462
1969  0.424013278  0.610388564  0.914971158  0.416263052
1970 -0.386397792  0.123261162 -0.093439841 -0.697294548
1971 -0.382660674 -0.662437618 -0.179715976  0.286294594
1972 -0.347354467  0.238452456 -0.004647615  0.655926059
1973  0.931020278  0.795300522  0.983287340  1.230959751
> adf_1_test <- adf.test(diff_1); adf_1_test

      Augmented Dickey-Fuller Test

data: diff_1
Dickey-Fuller = -3.9863, Lag order = 4, p-value = 0.01431
alternative hypothesis: stationary

>
>
```

P<alfa olduğundan dolayı birim kök yoktur, %95 güven düzeyinde seri durağandır denir. Birinci dereceden farkı almak seriyi durağanlaştırmaya yetmiştir.

```
bestmodel <- auto.arima(veri_capital_ts, trace = TRUE, ic="aicc", approximation = FALSE)
```

```
>
> bestmodel <- auto.arima(veri_capital_ts, trace = TRUE, ic="aicc", approximation = FALSE)

ARIMA(2,1,2)(1,0,1)[4] with drift      : 1067.837
ARIMA(0,1,0) with drift                : 1117.239
ARIMA(1,1,0)(1,0,0)[4] with drift      : 1061.017
ARIMA(0,1,1)(0,0,1)[4] with drift      : 1083.46
ARIMA(0,1,0)                          : 1125.629
ARIMA(1,1,0) with drift                : 1062.231
ARIMA(1,1,0)(2,0,0)[4] with drift      : 1062.991
ARIMA(1,1,0)(1,0,1)[4] with drift      : 1061.999
ARIMA(1,1,0)(0,0,1)[4] with drift      : 1060.477
ARIMA(1,1,0)(0,0,2)[4] with drift      : 1062.321
ARIMA(1,1,0)(1,0,2)[4] with drift      : 1064.306
ARIMA(0,1,0)(0,0,1)[4] with drift      : 1118.657
ARIMA(2,1,0)(0,0,1)[4] with drift      : 1062.196
ARIMA(1,1,1)(0,0,1)[4] with drift      : 1062.25
ARIMA(2,1,1)(0,0,1)[4] with drift      : 1064.521
ARIMA(1,1,0)(0,0,1)[4]                : 1060.797

Best model: ARIMA(1,1,0)(0,0,1)[4] with drift

>
>
```

Auto.arima fonksiyonu ile en iyi modeli seçmeye çalışıyoruz. AIC değeri en küçük olan ARIMA(1,1,0)(0,0,1) modelinin en iyi model olduğunu fonksiyon bize göstermektedir.

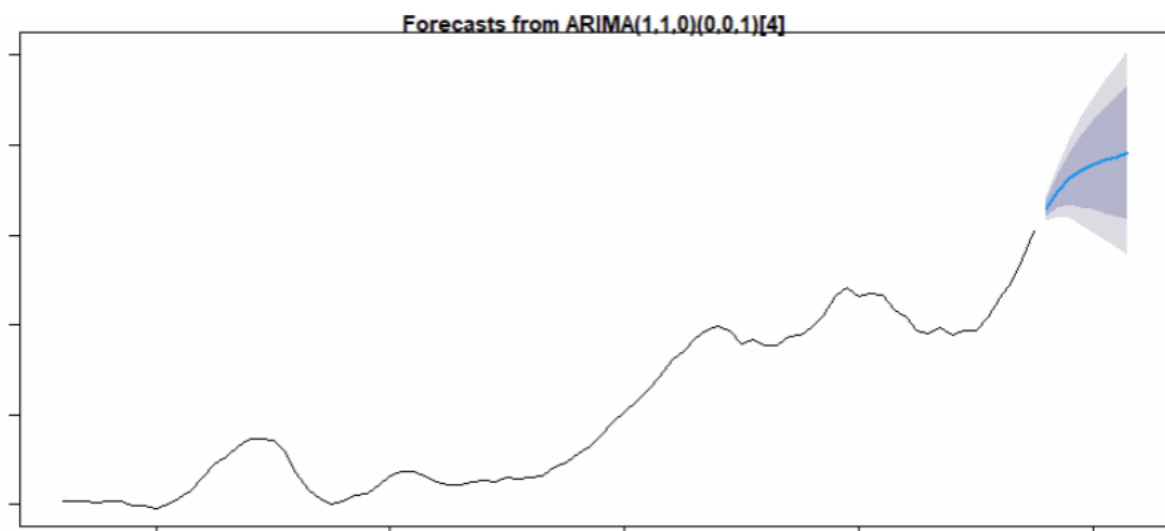
```
fitt <- Arima(veri_capital_ts,c(1,1,0), c(0,0,1))
```

```
forecast(fitt, h=4)
```

```
plot(forecast(fitt))
```

```
>  
>  
> fitt <- Arima(veri_capital_ts,c(1,1,0), c(0,0,1))  
> forecast(fitt, h=4)  
      Point Forecast      Lo 80      Hi 80      Lo 95      Hi 95  
1974 Q1      8591.884 8412.970 8770.798 8318.259 8865.51  
1974 Q2      8983.933 8612.043 9355.823 8415.176 9552.69  
1974 Q3      9267.333 8685.871 9848.795 8378.063 10156.60  
1974 Q4      9425.777 8627.842 10223.712 8205.441 10646.11  
>  
>  
>
```

*1974 yılının öngörüsü.




Tanı Analizi

Modelin anlamlı olup olmadığını kontrol etmek için artıkları inceliyoruz.

```
tsdisplay(residuals(bestmodel))
```

```
Acf(res, plot = TRUE)
```



Artıkların ACF grafiğini incelediğimizde durağan olmadığını görüyoruz.

```
shapiro.test(res)
```

```
> shapiro.test(res)

      Shapiro-Wilk normality test

data:  res
W = 0.98395, p-value = 0.3816

>
>
>
```

$P < \alpha$ olduğundan dolayı artıkların dağılımı normal dağılmamıştır.

```
Box.test(bestmodel$residuals, lag=10, type = "Ljung-Box")
```

```
>
> Box.test(bestmodel$residuals, lag=10, type = "Ljung-Box")

      Box-Ljung test

data:  bestmodel$residuals
X-squared = 16.343, df = 10, p-value = 0.09023

>
>
```

$P = 0.0923 > \alpha$ olduğundan artıkların ilişkisiz olduğunu görüyoruz.